TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Báo cáo đồ án Data Mining

Tiền xử lý dữ liệu

Sinh viên thực hiện:
23120146 – Hoàng Ngọc
23122021 – Bùi Duy Bảo
23122025 – Phạm Ngọc Duy
23122032 – Nguyễn Việt Hùng
23120266 – Võ Trần Duy Hoàng

Giảng viên hướng dẫn:
Th.S Nguyễn Thị Thu Hằng
Th.S Nguyễn Ngọc Đức
Th.S Lê Nhựt Nam

Thành phố Hồ Chí Minh, Tháng 4/2026

Mục lục

1 Tổng quan **3**
1.1 Giới thiệu . . . 3
1.2 Mục tiêu . . . 3

2 Cấu trúc dự án **4**
2.1 Cấu trúc thư mục toàn bộ dự án . . . 4
2.2 Cấu trúc các module chức năng . . . 5

3 Phân công **6**
3.1 Quản lí mã nguồn . . . 6
3.2 Phân chia công việc . . . 6

4 Thực nghiệm **8**
4.1 Dữ Liệu Thử Nghiệm . . . 9
4.1.1 Dữ liệu ảnh — Animals-10 . . . 9
4.1.2 Dữ liệu bảng — Building Permits . . . 10
4.1.3 Dữ liệu chuỗi thời gian — COVID-19 . . . 11
4.2 Thực nghiệm dữ liệu ảnh [1, 2, 3] . . . 12
4.2.1 N1. Phân tích phân bố pixel (Histogram/KDE) . . . 12
4.2.2 N2. Đánh giá độ tương phản và độ sáng . . . 12
4.2.3 N3. Phát hiện mất cân bằng lớp (Class Imbalance) . . . 13
4.2.4 N4. Phát hiện ảnh trùng lặp bằng pHash . . . 13
4.2.5 N5. Chuyển đổi không gian màu . . . 14
4.2.6 N6. Thay đổi kích thước ảnh và đánh giá chất lượng . . . 15
4.2.7 N7. Tăng cường dữ liệu (Data Augmentation) . . . 15
4.2.8 N8. Chuẩn hóa ảnh và kiểm định Kolmogorov-Smirnov . . . 16
4.2.9 N9 - Nâng cao: Phân tích không gian đặc trưng bằng PCA & t-SNE . . . 17
4.2.10 Nâng cao - N10. Phát hiện cạnh và phân tích đặc trưng cục bộ (Edge Density + ANOVA) . . . 19
4.3 Thực nghiệm dữ liệu bảng [4, 5, 6, 7, 8, 9] . . . 20
4.3.1 B1. Phân tích tương quan đa biến (Pearson & Spearman) . . . 20
4.3.2 B2. Phát hiện và xử lý ngoại lai . . . 20
4.3.3 B3. Chuẩn hóa dữ liệu có kiểm định . . . 21
4.3.4 B4. Mã hóa biến phân loại nâng cao . . . 22
4.3.5 B5. Lựa chọn và giảm chiều đặc trưng . . . 23
4.3.6 B6. Phát hiện và xử lý mất cân bằng lớp . . . 23
4.4 Thực nghiệm dữ liệu chuỗi thời gian [10, 11, 12, 13] . . . 25
4.4.1 T1. Phân tích thành phần dữ liệu thời gian . . . 25
4.4.2 T2. Kiểm định tính dừng bằng Rolling Statistics . . . 26

4.4.3 T3. Phân tích cấu trúc tương quan (ACF & PACF) 26
4.4.4 T4. Kiểm định tính dừng và biến đổi khử tính không dừng 27
4.4.5 T5. Phân rã chuỗi thời gian (Additive, Multiplicative, STL) 28
4.4.6 T6. Phát hiện dị thường trong chuỗi thời gian 28
4.4.7 T7. Xây dựng ma trận đặc trưng và dự báo $t + 1$ 29
4.4.8 Nâng cao - T8. Kiểm định nhân quả Granger (Bonus) 30

5 Môi trường và cài đặt **31**
5.0.1 Phần cứng 31
5.0.2 Phần mềm 31
5.0.3 Thư viện chính 31
5.1 Quản lý mã nguồn 32
5.1.1 Repository 32
5.1.2 Kiến trúc mã nguồn 32
5.2 Bộ dữ liệu 33
5.3 Hướng dẫn cài đặt và chạy thực nghiệm 33
5.3.1 Bước 1: Clone mã nguồn và tạo môi trường ảo 33
5.3.2 Bước 2: Cài đặt thư viện 33
5.3.3 Bước 3: Tải và đặt dataset 33
5.3.4 Bước 4: Chạy thực nghiệm 34

Tài liệu **34**

1 Tổng quan

1.1 Giới thiệu

Đồ án 1 – Tiền xử lý dữ liệu thuộc chương trình giảng dạy thực hành bộ môn **Khai Thác Dữ Liệu - CSC14004** của trường Đại học Khoa Học Tự Nhiên. Đồ án tập trung vào việc phân tích và tiền xử lý cho các loại dữ liệu nhằm giúp cho sinh viên hiểu và phải diễn giải dựa trên các đại lượng thống kê. Ngoài ra sinh viên còn được thực hiện phân tích trên các bộ dữ liệu thực tế nhằm giải quyết và đánh giá các tác động của các phương pháp sử dụng đối với câu hỏi cần trả lời.

Trong đồ án, giảng viên hướng dẫn yêu cầu phân tích trên nhiều kiểu dữ liệu. Nhóm đã lựa chọn và thực hiện phân tích trên các loại dữ liệu sau:

- **Dữ liệu ảnh**: Tập hợp xấp xỉ 26000 ảnh của 10 loại con vật cho bài toán phân loại.
- **Dữ liệu bảng**: Thu thập hơn 192000 records về việc ghi chép lại thông tin về các loại công trình trong thành phố và loại giấy phép cấp cho loại công trình đó.
- **Dữ liệu Time-Series**: Phân tích và đánh giá dữ liệu dạng chuỗi thời gian trong 10 tháng thời điểm đại dịch COVID, từ đó có thể xây dựng và dự báo các đợt bùng phát tiếp.

Trong đồ án còn giới thiệu rất nhiều về các phương pháp tiền xử lý, kiểm định, các biểu đồ trực quan hóa và đánh giá kết quả dựa trên các mô hình học máy. Nhìn chung tất cả đều nhằm hướng tới:

- **Biến đổi dữ liệu**: Thực hiện một hay nhiều bước, một hay nhiều phương pháp nhằm đạt được mục tiêu về mặt tính toán hoặc giải thích quan hệ của dữ liệu. Ngoài ra có thể đưa dữ liệu về cấu trúc mới để phục vụ cho mục đích riêng.
- **Trực quan hóa**: Thực hiện vẽ các biểu đồ để dễ dàng nắm và hiểu được thông tin dữ liệu thay vì chỉ đơn giản là những con số.
- **Kiểm định giả thuyết**: Thực hiện kiểm định để chứng minh kết quả có ý nghĩa về mặt thống kê chứ không phải suy diễn chủ quan.
- **Mô hình học máy**: Thực hiện huấn luyện mô hình và sử dụng các độ đo để đo hiệu suất của các phương pháp biến đổi dữ liệu.

1.2 Mục tiêu

Nhóm đặt ra mục tiêu bao gồm những yêu cầu trong đồ án và những yêu cầu khác để đảm bảo chất lượng đồ án bao gồm:

- **Chức năng**: Thực hiện xây dựng các hàm tiền xử lý được yêu cầu và các hàm tiện ích.

- **Phân tích**: Thực hiện phân tích bám sát với bộ dữ liệu, đặt câu hỏi và trực quan giải thích bằng số liệu và biểu đồ.
- **Mã nguồn**: Thực hiện thiết kế hàm trong file Python, phân tích và lý thuyết trên Jupyter Notebook, thiết kế hệ thống theo OOP dễ mở rộng và tái sử dụng. Xây dựng và quản lý repo bằng git và github.
- **Quản lý nhóm**: Thực hiện phân chia và chia đều tác vụ sao cho ai cũng đóng góp là như nhau, ai cũng phải nắm được cơ bản các phương pháp mình làm.
- **Báo cáo**: Thực hiện cung cấp đầy đủ tài liệu hướng dẫn sử dụng, cài đặt thư viện và các báo cáo kết luận về các phương pháp đã thực nghiệm.
- **Thực nghiệm**: Thực hiện đo nhiều lần, kiểm định giả thuyết và chọn các độ đo phù hợp để đánh giá.

2 Cấu trúc dự án

2.1 Cấu trúc thư mục toàn bộ dự án

```
data-mining-preprocessing-project/          # Thư mục gốc của dự án
|-- .git/                                   # Quản lý lịch sử phiên bản
|-- .venv/                                  # Môi trường ảo Python
|-- data/                                   # Dữ liệu đầu vào
|   |-- image/                              # Dữ liệu ảnh đầy đủ theo lớp
|   |-- small/                              # Dữ liệu ảnh rút gọn
|   |-- table/                              # Dữ liệu dạng bảng
|   |-- time_series/                        # Dữ liệu chuỗi thời gian
|-- docs/                                   # Tài liệu đề xuất và báo cáo
|-- notebooks/                              # Notebook thực nghiệm
|   |-- assets/                             # Các ảnh dùng trong notebook
|-- src/                                    # Mã nguồn chính
|   |-- config/                             # Cấu hình hệ thống
|   |-- core/                               # Lớp nền và kiến trúc dùng chung
|   |-- image/                              # Phân tích, xử lý ảnh
|   |-- table/                              # Phân tích, xử lý dữ liệu bảng
|   |-- time_series/                        # Phân tích, xử lý chuỗi thời gian
|   |-- statistic/                          # Kiểm định thống kê
|   |-- utils/                              # Hàm tiện ích tái sử dụng
|   |-- visualization/                      # Trực quan hóa dữ liệu và kết quả
```

Hình 1: Cấu trúc thư mục toàn bộ dự án và mô tả ngắn

2.2 Cấu trúc các module chức năng

```
src/                                        # Mã nguồn chính
|-- config/                                 # Cấu hình hệ thống
|   |-- settings.py                         # Khai báo tham số và đường dẫn
|   |-- __init__.py                         # Khởi tạo package config
|-- core/                                   # Lớp nền dùng chung
|   |-- data_base.py                        # Lớp cơ sở thao tác dữ liệu
|   |-- service_base.py                     # Lớp cơ sở cho pipeline xử lý
|   |-- test_base.py                        # Tiện ích nền phục vụ kiểm thử
|-- image/                                  # Xử lý dữ liệu ảnh
|   |-- dataset.py                          # Đọc dữ liệu ảnh, ánh xạ nhãn
|   |-- analysis_imbalance_class.py         # EDA mất cân bằng lớp
|   |-- preprocessing_color_transform.py    # Biến đổi không gian màu
|   |-- ....
|-- table/                                  # Xử lý dữ liệu bảng
|   |-- dataset.py                          # Đọc và tổ chức dữ liệu bảng
|   |-- analysis_missing_value.py           # EDA giá trị thiếu
|   |-- preprocessing_encoding.py           # Mã hóa biến phân loại
|   |-- ...
|-- time_series/                            # Xử lý chuỗi thời gian
|   |-- dataset.py                          # Đọc dữ liệu chuỗi thời gian
|   |-- analysis_rolling_statistic.py       # EDA rolling mean và std
|   |-- preprocessing_decomposition.py      # Tách trend, seasonal, residual
|   |-- ....
|-- statistic/                              # Kiểm định thống kê
|   |-- test_distribution.py                # Kiểm định phân phối
|   |-- test_missing.py                     # Kiểm định giá trị thiếu
|   |-- test_stationarity.py                # Kiểm định tính dừng
|-- utils/                                  # Hàm tiện ích dùng chung
|   |-- file.py                             # Tiện ích đọc ghi tệp
|   |-- metrics.py                          # Tính toán metric dùng chung
|-- visualization/                          # Trực quan hóa
|   |-- distribution.py                     # Biểu đồ phân phối
|   |-- relationship.py                     # Biểu đồ quan hệ biến
|   |-- ....
```

Hình 2: Một số module và mô tả ngắn

3 Phân công

3.1 Quản lí mã nguồn

Nhóm sử dụng Git và Github để tổ chức và quản lí mã nguồn, sau đây là những mốc thời gian chính:

- **11/3/2026 - 17/3/2026**: Họp lần 1, chọn tập dữ liệu ảnh và bảng, thực hiện làm lý thuyết cho dữ liệu ảnh bao gồm EDA và kiểm định KS Test.
- **18/3/2026 - 1/4/2026**: Họp lần 2, chọn tập dữ liệu chuỗi thời gian, thực hiện tiền xử lý cho dữ liệu ảnh và EDA cho dữ liệu bảng.
- **1/4/2026 - 8/4/2026**: Thực hiện tiền xử lý cho dữ liệu bảng, thực hiện EDA cho dữ liệu chuỗi thời gian, bắt đầu viết báo cáo
- **9/4/2026 - 16/4/2026**: Họp lần 3, viết báo cáo, thêm section cho notebook, viết mô tả cho Dataset.
- **17/4/2026 - 23/4/2026**: Hoàn thiện báo cáo, chuẩn bị bài nộp.

Dưới đây là quá trình phát triển repository và mức độ commit trong nhóm trong giai đoạn từ 9/3/20206 - 23/4/2026

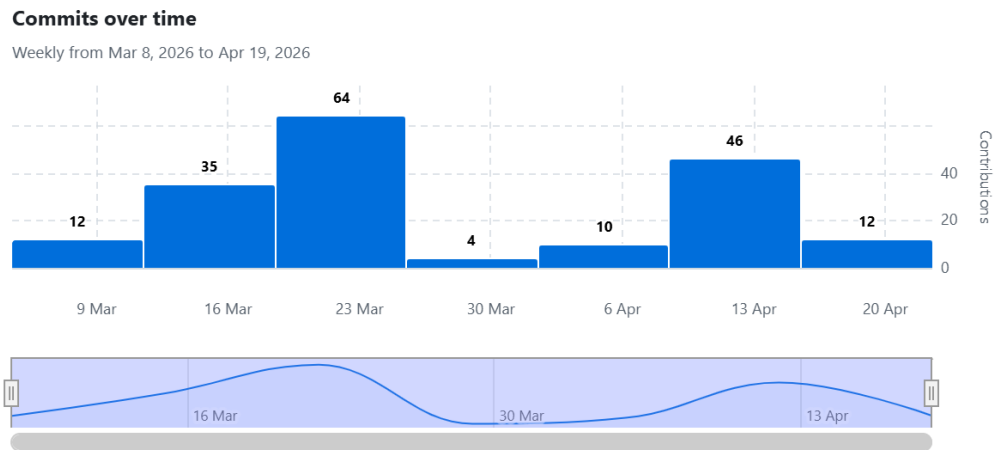

Hình 3: Quá trình phát triển và đóng góp commit của nhóm

3.2 Phân chia công việc

Bảng 1: Bảng phân công công việc [14]

STT	Công việc	Loại	Nội dung công việc	Phân công
1	Phân tích chất lượng ảnh	Dữ liệu ảnh	Phân tích histogram, contrast/brightness, pixel pattern, mức mất cân bằng lớp.	Duy, Ngọc, Bảo
2	Tiền xử lý ảnh cơ bản	Dữ liệu ảnh	Resize, normalization, color conversion, data augmentation.	Hoàng, Ngọc, Bảo
3	Khử trùng lặp ảnh	Dữ liệu ảnh	Phát hiện và loại ảnh trùng lặp.	Hùng, Ngọc
4	Kiểm tra missing value	Dữ liệu bảng	Phân tích dữ liệu thiếu, đánh giá mức độ thiếu và ảnh hưởng.	Duy, Ngọc
5	Kiểm định phân phối	Dữ liệu bảng	Kiểm tra phân phối để chọn phương pháp xử lý/kiểm định phù hợp.	Ngọc, Duy
6	Phân tích tương quan bảng	Dữ liệu bảng	Phân tích tương quan giữa các biến để hiểu cấu trúc đặc trưng.	Hùng, Ngọc
7	Phát hiện outlier bảng	Dữ liệu bảng	Áp dụng IQR, Z-score, Isolation Forest, LOF, DBSCAN để phát hiện ngoại lai.	Hoàng, Ngọc
8	Chuẩn hóa dữ liệu số	Dữ liệu bảng	Chuẩn hóa dữ liệu số bằng min-max, z-score, robust scaling.	Ngọc
9	Encoding + Feature Selection	Dữ liệu bảng	Categorical encoding và feature selection/dimensionality reduction.	Ngọc, Bảo
10	Phân tích cấu trúc chuỗi	Dữ liệu chuỗi time	Stationarity testing, rolling statistics, correlation structure, data components.	Hùng, Ngọc, Bảo
11	Decomposition chuỗi thời gian	Dữ liệu chuỗi time	Phân rã chuỗi bằng additive, multiplicative, STL để tách trend/seasonal/residual.	Duy, Ngọc
12	Phát hiện outlier time series	Dữ liệu chuỗi time	Xác định điểm bất thường trên chuỗi thời gian để làm sạch dữ liệu.	Ngọc, Hoàng

STT	Công việc	Dữ liệu	Nội dung công việc	Phân công
13	Tạo feature matrix dự báo	Dữ liệu chuỗi time	Tạo ma trận đặc trưng cho bài toán dự báo chuỗi thời gian.	Ngọc
14	Viết báo cáo	Báo cáo	Viết nội dung mô tả dataset, giới thiệu, thực nghiệm, cài đặt...	Ngọc, Duy, Hùng, Bảo, Hoàng
15	Quản lý nhóm	Hoạt động	Họp nhóm, đảm bảo tiến độ, phân công,...	Ngọc
16	Phân tích PCA trên không gian đặc trưng ảnh	Dữ liệu ảnh	Thực hiện làm phần bonus nâng cao cho dữ liệu ảnh về phân tích PCA	Hùng
17	Granger testing	Dữ liệu chuỗi time	Thực hiện bonus nâng cao kiểm định quan hệ nhân quả Granger giữa các biến chuỗi thời gian.	Ngọc
18	Phát hiện cạnh và phân tích đặc trưng cục bộ	Dữ liệu ảnh	Thực hiện bonus nâng cao, áp dụng Sobel, Prewitt và Canny với ít nhất 2 bộ siêu tham số mỗi loại và tính Edge Density	Hùng
19	Phát hiện và xử lý mất cân bằng lớp	Dữ liệu bảng	Thực hiện bonus nâng cao, Áp dụng SMOTE, ADASYN và Random Under-sampling và đánh giá mô hình trên tập test chưa tái cân bằng.	Duy
20	Làm sạch mã nguồn	Hoạt động	Thực hiện chú thích mã nguồn, đảm bảo notebook chạy và package đầy đủ	Hùng, Ngọc, Duy, Bảo, Hoàng.

4 Thực nghiệm

Trong phần thực nghiệm này, nhóm tập trung phân tích, tiền xử lý và huấn luyện mô hình và đánh giá nó bằng nhiều phương pháp khác nhau. Các báo cáo dưới đây chỉ là báo cáo tổng quan các chỉ số quan trọng cho người đọc nắm bắt được tổng quan, còn nếu muốn diễn giải chi tiết và có lập luận thì nên vào notebook để đọc vì nhóm đã rất có gắng và làm chăm chút nên sẽ dễ hiểu hơn.

4.1 Dữ Liệu Thử Nghiệm

4.1.1 Dữ liệu ảnh — Animals-10

Tổng quan: Bộ dữ liệu **Animals-10** [15] được đóng góp bởi tác giả *Alessio Corrado* trên nền tảng Kaggle. Bộ dữ liệu bao gồm ảnh màu (RGB) của 10 loài động vật phổ biến, được thu thập từ nhiều nguồn trên Internet. Mục tiêu chính là phục vụ bài toán **phân loại ảnh đa lớp** (Multi-class Image Classification). Đặc điểm nổi bật là tên thư mục gốc được đặt bằng tiếng Ý, cần chuyển đổi sang tiếng Anh trước khi sử dụng.

Đặc điểm	**Giá trị**
Tổng số ảnh	26.179
Số lớp (class)	10
Không gian màu	RGB (3 kênh)
Kích thước ảnh	Đa dạng (không đồng nhất)
Định dạng	JPEG

Bảng 2: Đặc điểm tổng quan bộ dữ liệu Animals-10

Lớp	**Số ảnh**	**Lớp**	**Số ảnh**
dog	4.863	cow	1.866
spider	4.821	squirrel	1.862
chicken	3.098	sheep	1.820
horse	2.623	cat	1.668
butterfly	2.112	elephant	1.446

Bảng 3: Phân bố số lượng ảnh theo lớp

Đặc điểm bộ dữ liệu.

Thách thức.

1. **Mất cân bằng lớp:** Lớp `dog` có 4.863 ảnh, gấp 3,4 lần lớp `elephant` (1.446 ảnh). Tỷ lệ mất cân bằng (IR $\approx$ 3,4:1) ở mức nhẹ nhưng có thể gây thiên kiến cho mô hình.

2. **Kích thước ảnh không đồng nhất:** Ảnh có kích thước từ vài chục đến vài nghìn pixel, bắt buộc phải resize trước khi đưa vào mô hình, dẫn đến mất mát thông tin.

3. **Ảnh trùng lặp và nhiễu:** Một số ảnh có nội dung gần giống nhau hoặc chứa nhiều đối tượng, gây nhiễu cho quá trình huấn luyện.

4. **Phân bố pixel không đồng nhất:** Các kênh R, G, B có phân bố cường độ khác nhau, cần lựa chọn phương pháp chuẩn hóa phù hợp.

4.1.2 Dữ liệu bảng — Building Permits

Tổng quan: Bộ dữ liệu **Building Permits** [16] được đóng góp bởi tác giả *Aparna Shastry* trên Kaggle, nguồn gốc từ cổng dữ liệu mở của thành phố San Francisco (SF OpenData). Bộ dữ liệu ghi nhận thông tin giấy phép xây dựng gồm loại công trình, chi phí ước tính, địa chỉ, trạng thái xử lý, v.v. Mục tiêu sử dụng là phục vụ các thực nghiệm **tiền xử lý dữ liệu bảng**: kiểm định phân phối, xử lý giá trị thiếu, phát hiện ngoại lai, chuẩn hóa và mã hóa biến phân loại.

Đặc điểm	**Giá trị**
Số dòng (records)	198.900
Số cột (features)	43
Số cột kiểu số (numeric)	15 (3 `int64` + 12 `float64`)
Số cột kiểu chữ (categorical)	28 (`object`)
Tỷ lệ thiếu trung bình	26,26%
Số cột không thiếu dữ liệu	12 / 43
Số cột thiếu > 95%	4 cột (ví dụ `TIDF Compliance`: 99,99%)

Bảng 4: Đặc điểm tổng quan bộ dữ liệu Building Permits

Đặc điểm bộ dữ liệu.

Thách thức.

1. **Thiếu dữ liệu nghiêm trọng:** Tỷ lệ thiếu trung bình 26,26% trên toàn tập, trong đó 4 cột có tỷ lệ thiếu > 95%. Cần phân loại cơ chế thiếu (MCAR/MAR/MNAR) trước khi lựa chọn chiến lược xử lý.

2. **Phân phối lệch cực mạnh:** Các cột chi phí (`Estimated Cost`, `Revised Cost`) bị lệch phải nghiêm trọng do phần lớn giấy phép là sửa chữa nhỏ, trong khi một số ít dự án lớn có giá trị cực cao. Điều này khiến IQR và Z-Score phát hiện ngoại lai kém hiệu quả.

3. **Biến phân loại có cardinality cao:** Các cột như `Street Name`, `Description` có hàng nghìn giá trị duy nhất, gây bùng nổ chiều khi sử dụng One-hot Encoding.

4. **Đa cộng tuyến:** Nhiều cặp cột ngày tháng (`Filed Date`, `Issued Date`, `Completed Date`) và chi phí (`Estimated Cost`, `Revised Cost`) có tương quan rất cao, cần lọc đặc trưng trước khi đưa vào mô hình.

4.1.3 Dữ liệu chuỗi thời gian — COVID-19

Tổng quan: Bộ dữ liệu **COVID-19 Time Series** [17] được đóng góp bởi tác giả *Niket Chauhan* trên Kaggle, tổng hợp từ nguồn dữ liệu của Đại học Johns Hopkins (JHU CSSE). Bộ dữ liệu ghi nhận số ca nhiễm, tử vong và phục hồi tích lũy theo ngày tại 189 quốc gia/vùng lãnh thổ, từ ngày 22/01/2020 đến 17/10/2020. Mục tiêu sử dụng là phục vụ các thực nghiệm **phân tích và tiền xử lý chuỗi thời gian**: kiểm định tính dừng, phân rã, phát hiện dị thường, xây dựng đặc trưng dự báo.

Đặc điểm	**Giá trị**
Số dòng (records)	72.090
Số cột (features)	8
Khoảng thời gian	22/01/2020 – 17/10/2020 (270 ngày)
Số quốc gia/vùng lãnh thổ	189
Biến mục tiêu	`Confirmed`, `Deaths`, `Recovered`
Tỷ lệ thiếu trung bình	9,36% (chủ yếu ở `Province/State` và `Recovered`)
Kiểu cột	3 `object` + 3 `float64` + 2 `int64`

Bảng 5: Đặc điểm tổng quan bộ dữ liệu COVID-19 Time Series

Đặc điểm bộ dữ liệu.

Thách thức.

1. **Tính không dừng (Non-stationarity):** Cả 3 biến mục tiêu đều là dữ liệu tích lũy, có xu hướng tăng liên tục theo thời gian. Cần biến đổi (sai phân, logarit) trước khi áp dụng các mô hình chuỗi thời gian.

2. **Tính mùa vụ hành chính:** Dữ liệu có hiệu ứng chu kỳ tuần ($period = 7$): số ca giảm vào cuối tuần do giảm xét nghiệm và báo cáo, tăng vọt vào đầu tuần do dồn báo cáo. Đây không phải tính mùa vụ sinh học mà là nhiễu hành chính.

3. **Lỗi báo cáo và dị thường dữ liệu:** Một số ngày ghi nhận giá trị đột biến do dồn báo cáo, điều chỉnh số liệu hồi cứu, hoặc thay đổi tiêu chí thống kê giữa các quốc gia, gây khó khăn cho việc phân biệt dị thường thật và nhiễu dữ liệu.

4. **Tính không đồng nhất giữa các quốc gia:** Mỗi quốc gia có đặc điểm dịch tễ, năng lực y tế và chính sách chống dịch khác nhau, dẫn đến phân bố dữ liệu rất khác biệt. Không thể áp dụng rập khuôn một phương pháp tiền xử lý cho mọi khu vực.

4.2 Thực nghiệm dữ liệu ảnh [1, 2, 3]

Dưới đây là một số thực nghiệm trên bộ dữ liệu ảnh phân loại động vật gồm 10 lớp (`dog, spider, cat, sheep, elephant, chicken, butterfly, cow, squirrel, horse`) với tổng cộng 26.179 ảnh.

- Bộ dữ liệu ảnh RGB có kích thước đa dạng, cần tiền xử lý trước khi đưa vào mô hình.
- Các thực nghiệm bao gồm: phân tích phân bố pixel, đánh giá độ tương phản & độ sáng, phát hiện mất cân bằng lớp, phát hiện ảnh trùng lặp, chuyển đổi không gian màu, thay đổi kích thước, tăng cường dữ liệu và chuẩn hóa ảnh.

4.2.1 N1. Phân tích phân bố pixel (Histogram/KDE)

Phân tích phân bố cường độ pixel trên ba kênh màu R, G, B bằng Histogram và KDE (Kernel Density Estimation). Mục tiêu là đánh giá sự đồng nhất phân bố giữa các kênh, từ đó hỗ trợ lựa chọn phương pháp chuẩn hóa phù hợp.

Chỉ số	**Giá trị**	**Nhận xét**
Phân bố giá trị kênh Red	100–200 (xấp xỉ)	Tập trung vùng cường độ trung–cao.
Phân bố giá trị kênh Green	50–200 (xấp xỉ)	Phân tán rộng hơn Red.
Phân bố giá trị kênh Blue	0–100 (xấp xỉ)	Lệch về vùng cường độ thấp.

Bảng 6: N1 – Chỉ số phân bố pixel theo kênh màu

Nhận xét: Kết quả cho thấy phân bố cường độ giữa các kênh RGB không đồng nhất: kênh Red tập trung ở vùng cường độ trung–cao, kênh Green phân tán rộng hơn, và kênh Blue lệch về vùng cường độ thấp. Sự khác biệt này phản ánh đặc thù của bộ dữ liệu ảnh thiên nhiên (nhiều cảnh ngoài trời với tông xanh lá cây và ánh sáng tự nhiên). Kết quả hỗ trợ quyết định lựa chọn bước chuẩn hóa phù hợp: nên ưu tiên Z-Score Channel-wise để cân bằng phân bố giữa các kênh thay vì chuẩn hóa toàn cục.

4.2.2 N2. Đánh giá độ tương phản và độ sáng

Đánh giá độ sáng (Mean Intensity) và độ tương phản (Standard Deviation) của ảnh trên toàn bộ tập dữ liệu. Sử dụng Box Plot để so sánh sự phân bố giữa các lớp động vật.

Chỉ số	Cách tính	Ý nghĩa
Độ sáng (Brightness)	Trung bình cường độ pixel (μ)	Đánh giá mức sáng trung bình của ảnh.
Độ tương phản (Contrast)	Độ lệch chuẩn cường độ (σ)	Đánh giá sự chênh lệch sáng–tối trong ảnh.

Bảng 7: N2 – Các chỉ số đánh giá độ sáng và tương phản

Nhận xét: Kết quả Box Plot cho thấy sự phân bố độ sáng và độ tương phản khác nhau rõ rệt giữa các lớp. Một số lớp (ví dụ `sheep`, `butterfly`) có xu hướng sáng hơn do môi trường chụp thường là ngoài trời, trong khi các lớp như `spider`, `cat` có độ tương phản cao hơn. Điều này cho thấy cần cân nhắc bước chuẩn hóa độ sáng/tương phản trước khi huấn luyện mô hình để tránh thiên kiến do điều kiện chụp ảnh gây ra.

4.2.3 N3. Phát hiện mất cân bằng lớp (Class Imbalance)

Phân tích sự phân bố số lượng ảnh giữa các lớp để xác định mức độ mất cân bằng. Sử dụng tỷ lệ mất cân bằng (Imbalance Ratio – IR) $= \frac{\text{Majority Class}}{\text{Minority Class}}$ để đánh giá.

Mức độ	IR	Ảnh hưởng
Nhẹ (Mild)	1:1 – 9:1	Ảnh hưởng ít đến hiệu suất mô hình.
Trung bình (Moderate)	10:1 – 100:1	Ranh giới phân lớp bị lấn át bởi lớp đa số.
Nghiêm trọng (Extreme)	$>$ 100:1	Lớp thiểu số bị coi là nhiễu.

Bảng 8: N3 – Phân loại mức độ mất cân bằng lớp

Nhận xét: Mất cân bằng lớp khiến Accuracy trở nên vô nghĩa: mô hình có thể đạt độ chính xác rất cao bằng cách luôn dự đoán lớp đa số. Cần sử dụng các độ đo bổ sung như Sensitivity (Recall) và Specificity. Chi phí dự đoán sai giữa False Negative và False Positive là khác nhau đáng kể. Với bộ dữ liệu 10 lớp động vật hiện tại, mức mất cân bằng ở mức nhẹ, tuy nhiên cần lưu ý khi áp dụng Data Augmentation để cân bằng số lượng mẫu giữa các lớp.

4.2.4 N4. Phát hiện ảnh trùng lặp bằng pHash

Sử dụng thuật toán Perceptual Hashing (pHash) dựa trên DCT (Discrete Cosine Transform) để tạo dấu vân tay 64-bit cho mỗi ảnh, sau đó so sánh bằng Khoảng cách Hamming để phát hiện ảnh trùng lặp hoặc gần trùng lặp.

Mức tương đồng	Hamming Distance	Nhận xét
Giống hệt / gần giống	0 – 5	Ảnh trùng lặp hoặc chỉ khác biệt rất nhỏ.
Tương tự	6 – 10	Ảnh có nội dung tương tự nhưng khác một số chi tiết.
Khác biệt	> 10	Hai ảnh hoàn toàn khác nhau.

Bảng 9: N4 – Phân loại mức độ tương đồng dựa trên Khoảng cách Hamming

Nhận xét:

1. pHash bền vững trước các thay đổi nhỏ như resize, nén, chỉnh sáng nhẹ – khác biệt cốt lõi so với hàm băm mật mã (MD5, SHA-256).
2. Thuật toán hoạt động qua 6 bước: giảm kích thước (32×32), chuyển grayscale, tính DCT, chắt lọc ma trận 8×8, tính trung bình, và tạo mã băm nhị phân 64-bit.
3. Việc lọc ảnh trùng lặp giúp giảm thiên kiến trong tập huấn luyện và cải thiện khả năng tổng quát hóa của mô hình.
4. Đề xuất cải tiến: Ensemble Hashing (kết hợp nhiều hàm băm), Rotation Invariance (bất biến phép xoay), và Dynamic Thresholding (ngưỡng động).

4.2.5 N5. Chuyển đổi không gian màu

So sánh các không gian màu RGB, Grayscale, HSV và LAB. Đánh giá khả năng bảo toàn thông tin bằng Phương sai giải thích (PCA) và hiệu năng phân loại bằng F1-Score.

Không gian	Số kênh	Đặc điểm chính	Ứng dụng
RGB	3	Biểu diễn trực tiếp qua R, G, B $\in [0, 255]$.	Hiển thị màn hình, lưu trữ.
Grayscale	1	Chỉ giữ thông tin cường độ sáng.	Giảm chiều, tăng tốc xử lý.
HSV	3	Hue $[0, 179]$, Saturation, Value $[0, 255]$.	Phân đoạn theo màu sắc.
LAB	3	L (sáng), a (đỏ–xanh lá), b (vàng–xanh dương).	Xử lý ảnh gần nhận thức thị giác.

Bảng 10: N5 – So sánh các không gian màu

Nhận xét:

1. **Về phương sai giải thích (PCA):** RGB giữ lại nhiều thông tin nhất do có 3 kênh màu đầy đủ. Grayscale mất nhiều thông tin màu sắc nhưng bù lại giảm đáng kể chiều dữ liệu.

2. **Về F1-Score phân loại:** Không gian RGB và LAB cho F1-Score cao hơn HSV và Grayscale trong bài toán phân loại động vật, cho thấy thông tin màu sắc đóng vai trò quan trọng.

3. **Đánh đổi:** Số kênh màu nhiều hơn không luôn đồng nghĩa với hiệu năng tốt hơn. LAB với khả năng tách biệt thông tin sáng và màu cho kết quả cạnh tranh với RGB nhưng có thể bền vững hơn trước sự thay đổi điều kiện chiếu sáng.

4.2.6 N6. Thay đổi kích thước ảnh và đánh giá chất lượng

Thực hiện Ablation Study với các kích thước mục tiêu khác nhau. Đánh giá chất lượng ảnh sau resize bằng PSNR (Peak Signal-to-Noise Ratio) và SSIM (Structural Similarity Index). Đánh giá hiệu năng phân loại bằng SGD Classifier với Cross-Validation 3-Fold.

Chỉ số	**Công thức**	**Ý nghĩa**
PSNR (dB)	$PSNR = 10 \cdot \log_{10}\left(\frac{MAX_I^2}{MSE}\right)$	> 40: cực tốt; 30–40: tốt; < 25: kém.
SSIM $[0, 1]$	$SSIM = \frac{(2\mu_x\mu_y+C_1)(2\sigma_{xy}+C_2)}{(\mu_x^2+\mu_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2)}$	≈ 1: giống gốc; 0,5–0,8: biến dạng.

Bảng 11: N6 – Hai chỉ số đánh giá chất lượng ảnh (IQA)

Nhận xét:

1. PSNR đánh giá thuần túy về mặt vật lý (sai số pixel), trong khi SSIM đánh giá dựa trên cảm nhận thị giác con người qua ba thành phần: Luminance, Contrast, Structure.

2. Khi kích thước resize giảm, cả PSNR và SSIM đều giảm do mất mát thông tin. Tuy nhiên, kích thước quá lớn lại làm tăng chi phí tính toán mà không cải thiện đáng kể hiệu năng phân loại.

3. Cần tìm kích thước tối ưu cân bằng giữa chất lượng ảnh (PSNR/SSIM cao) và hiệu năng tính toán. Kích thước 64×64 thường là lựa chọn cân bằng cho bài toán phân loại đơn giản.

4.2.7 N7. Tăng cường dữ liệu (Data Augmentation)

Áp dụng 3 thử nghiệm tăng cường dữ liệu, đánh giá bằng t-SNE và LogisticRegression (SGD). Ảnh được resize về 64×64 để đảm bảo tính nhất quán. Đánh giá chạy 3 lần với random_state khác nhau, lấy trung bình.

Thử nghiệm	Mô tả	Best F1	Nhận xét
Baseline	Không augmentation.	0,2755	Ngưỡng cơ sở.
TN1	Áp dụng đúng 1 phép biến đổi riêng lẻ.	0,2880	Rotate cho cải thiện tốt nhất.
TN2	Tổ hợp 3 phép biến đổi tuần tự.	0,2859	Một số tổ hợp làm giảm F1.
TN3	8 pipeline cụ thể (4 nhóm × 2 biến thể, 5 phép).	0,2774	Pipeline phức tạp không luôn tốt hơn.

Bảng 12: N7 – Kết quả 3 thử nghiệm tăng cường dữ liệu

Nhận xét:

1. **Phép biến đổi đơn lẻ (TN1):** Rotate cho F1 cao nhất (0,2880), cải thiện nhẹ so với Baseline. Horizontal Flip và Random Crop cũng cho kết quả tương đương. Brightness thay đổi ít hiệu quả.
2. **Tổ hợp 3 phép (TN2):** Không phải mọi tổ hợp đều tốt hơn phép đơn lẻ. Một số tổ hợp như HFlip-Rotate-Bright ($F1 = 0,2509$) thậm chí làm giảm hiệu năng.
3. **Pipeline 5 phép (TN3):** Tổ hợp quá nhiều phép biến đổi có thể làm biến dạng đặc trưng, khiến mô hình khó học. Kết quả cho thấy "nhiều hơn không phải lúc nào cũng tốt hơn".
4. **Kết luận:** Nên ưu tiên các phép augmentation đơn giản, bảo toàn cấu trúc ảnh (Rotate, Horizontal Flip) và tránh tổ hợp quá nhiều phép biến đổi.

4.2.8 N8. Chuẩn hóa ảnh và kiểm định Kolmogorov-Smirnov

Cài đặt và so sánh 4 phương pháp chuẩn hóa ảnh. Sử dụng kiểm định Kolmogorov-Smirnov (KS Test) hai mẫu để đánh giá sự khác biệt phân phối trước và sau chuẩn hóa, cùng các tiêu chí đánh giá chuẩn hóa và hiệu năng mô hình SGD Classifier.

Phương pháp	Công thức	Đặc điểm
MinMax $[0, 1]$	$x' = \frac{x-\min(x)}{\max(x)-\min(x)+\epsilon}$	Giữ quan hệ tuyến tính, nhạy outlier.
MinMax $[-1, 1]$	$x' = 2 \cdot \frac{x-\min(x)}{\max(x)-\min(x)+\epsilon} - 1$	Dịch tâm về 0, nhạy outlier.
Z-Score Global	$x' = \frac{x-\mu}{\sigma+\epsilon}$ (toàn bộ kênh)	Giữ tỷ lệ cường độ giữa các kênh.
Z-Score Channel-wise	$x'_i = \frac{x_i-\mu_i}{\sigma_i+\epsilon}$ (từng kênh)	Cân bằng trắng, loại bỏ sai lệch màu.

Bảng 13: N8 – So sánh 4 phương pháp chuẩn hóa ảnh

Nhận xét:

1. **Kiểm định KS Test:** Kết quả mong đợi là bác bỏ H_0 ($D \approx 1{,}0$; p-value ≈ 0), xác nhận phép chuẩn hóa đã thay đổi phân phối pixel thành công. Nếu p-value $> \alpha = 0{,}05$ (chấp nhận H_0), đó là tín hiệu bất thường cho thấy chuẩn hóa không hoạt động.

2. **Tiêu chí đánh giá:** Ba tiêu chí chính gồm (a) tính dịch tâm về 0 – tránh hiện tượng zigzag khi tối ưu, (b) tính đồng nhất dải giá trị – tránh Exploding/Vanishing Gradient, (c) bảo toàn phân phối – giữ hình dạng Histogram tương đồng ảnh gốc.

3. **MinMax** đơn giản nhưng cực kỳ nhạy cảm với nhiễu (outlier pixel). **Z-Score Channel-wise** hoạt động như kỹ thuật cân bằng trắng, phù hợp khi ảnh chụp ở nhiều điều kiện ánh sáng khác nhau.

4. Cần kết hợp cả đánh giá thống kê (KS Test) và đánh giá hiệu năng mô hình (SGD Classifier) để lựa chọn phương pháp chuẩn hóa tối ưu cho bài toán cụ thể.

4.2.9 N9 - Nâng cao: Phân tích không gian đặc trưng bằng PCA & t-SNE

Phân tích không gian đặc trưng (Feature Space Analysis) nhằm mục đích giảm chiều dữ liệu ảnh từ không gian cao chiều ($D = 49\,152$ chiều, ứng với ảnh $128 \times 128 \times 3$ kênh RGB) xuống không gian thấp chiều để đánh giá khả năng phân tách lớp (class separability) và cấu trúc phân cụm (clustering structure) của tập dữ liệu.

Bước 1 – Chuẩn bị dữ liệu. Thu thập $N = 2\,000$ ảnh (lấy mẫu đều 200 ảnh mỗi lớp, tổng cộng 10 lớp). Mỗi ảnh được biến đổi thành vector đặc trưng $\mathbf{x}_i \in \mathbb{R}^D$ với $D = 49\,152$. Sau đó, dữ liệu được chuẩn hóa (standardize) bằng z-score:

$$\hat{x}_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \qquad j = 1, \ldots, D$$

trong đó μ_j và σ_j lần lượt là trung bình và độ lệch chuẩn của chiều thứ j trên toàn bộ tập mẫu.

Phương pháp	Công thức / Mô tả	Mục đích
PCA	$\mathbf{C} = \frac{1}{N-1}\hat{\mathbf{X}}^\top\hat{\mathbf{X}}, \quad \mathbf{C}\mathbf{v}_k = \lambda_k \mathbf{v}_k$	Giữ cấu trúc toàn cục; xác định số chiều cần thiết qua Scree Plot (tỉ lệ phương sai giải thích).
Tỉ lệ phương sai	$r_k = \dfrac{\lambda_k}{\sum_{j=1}^{D}\lambda_j}, \quad R_K = \sum_{k=1}^{K} r_k$	r_k: phương sai giải thích bởi thành phần chính thứ k; R_K: phương sai tích lũy khi giữ K thành phần.
t-SNE	$p_{j\|i} = \frac{\exp(-\|\mathbf{x}_i-\mathbf{x}_j\|^2/2\sigma_i^2)}{\sum_{k\neq i}\exp(-\|\mathbf{x}_i-\mathbf{x}_k\|^2/2\sigma_i^2)}$	Bảo toàn cấu trúc cục bộ; trực quan hóa phân cụm 2D/3D.

Bảng 14: Công thức và phương pháp giảm chiều được sử dụng

Bước 2 – Phân rã PCA và Scree Plot. Thực hiện phân rã PCA trên ma trận dữ liệu chuẩn hóa $\hat{\mathbf{X}} \in \mathbb{R}^{N\times D}$ để tìm $K = 2\,000$ thành phần chính. Kết quả Scree Plot thể hiện tỉ lệ phương sai giải thích (r_k) và phương sai tích lũy (R_K) theo số thành phần chính K.
Nhận xét Scree Plot:

- Các thành phần chính đầu tiên chiếm tỷ lệ phương sai giải thích lớn, cho thấy thông tin phân biệt giữa các lớp tập trung vào một số ít chiều chính.
- Đường phương sai tích lũy (R_K) cho thấy có thể giữ lại phần lớn thông tin ($> 90\%$) với số chiều nhỏ hơn rất nhiều so với $D = 49\,152$ ban đầu – minh chứng cho hiệu quả của PCA trong việc giảm chiều không gian đặc trưng ảnh.
- Điều này xác nhận sự tồn tại của hiện tượng "Lời nguyền chiều dữ liệu" (Curse of Dimensionality): phần lớn 49 152 chiều là dư thừa hoặc chứa nhiễu, không đóng góp đáng kể cho việc phân biệt lớp.

Bước 3 – Trực quan hóa t-SNE 2D & 3D. Áp dụng thuật toán t-SNE lên dữ liệu đã chuẩn hóa để chiếu xuống không gian 2 chiều và 3 chiều. Kết quả được trực quan hóa bằng Scatter Plot, trong đó mỗi điểm tương ứng với một ảnh, màu sắc đại diện cho nhãn lớp.
Nhận xét Scatter Plot 2D & 3D:

- Nếu các cụm điểm theo lớp tách biệt rõ ràng trên biểu đồ t-SNE $\Rightarrow$ dữ liệu ảnh có cấu trúc phân cụm tốt, các đặc trưng pixel đủ sức phân biệt lớp.
- Nếu các cụm chồng chéo nhiều $\Rightarrow$ đặc trưng thô (raw pixel) chưa đủ để phân biệt, cần các phương pháp trích xuất đặc trưng nâng cao (ví dụ: CNN, HOG, SIFT).
- Kết hợp PCA và t-SNE cho phép đánh giá cả cấu trúc toàn cục (PCA) lẫn cấu trúc cục bộ (t-SNE) của không gian đặc trưng, hỗ trợ quyết định chiến lược tiền xử lý và lựa chọn mô hình phù hợp.

Kết luận phân tích không gian đặc trưng:

1. PCA xác nhận rằng không gian đặc trưng 49 152 chiều có thể giảm đáng kể mà vẫn giữ được phần lớn thông tin – hỗ trợ việc giảm chi phí tính toán và tránh overfitting.

2. t-SNE cung cấp trực quan hóa hữu ích để đánh giá chất lượng phân cụm và khả năng phân tách lớp của tập dữ liệu.

3. Sự kết hợp hai phương pháp cho bức tranh toàn diện về cấu trúc dữ liệu ảnh, là cơ sở cho các bước tiền xử lý và lựa chọn mô hình tiếp theo.

4.2.10 Nâng cao - N10. Phát hiện cạnh và phân tích đặc trưng cục bộ (Edge Density + ANOVA)

Trên tập dữ liệu ảnh động vật (10 lớp), thực hiện trích xuất đặc trưng mật độ cạnh bằng 3 phương pháp phát hiện cạnh (Canny, Sobel, Prewitt) với 6 cấu hình tham số và kiểm định One-Way ANOVA để đánh giá khả năng phân biệt lớp.

$$\text{Edge Density} = \frac{\text{Số pixel cạnh}}{\text{Tổng số pixel ảnh}}$$

Phương pháp	**Cấu hình**	**Kết quả thực nghiệm nổi bật**
Canny	$(50, 150)$	Cho khả năng tách lớp tốt nhất; ANOVA đạt $F = 19.15$, $p = 9.6 \times 10^{-30}$.
Canny	$(100, 200)$	Vẫn có ý nghĩa thống kê mạnh ($p \ll 0.05$), nhưng mức phân tách giảm nhẹ so với cấu hình nhạy hơn.
Sobel	Threshold $= 50, 100$	Cả hai cấu hình đều cho khác biệt có ý nghĩa giữa các lớp ($p \ll 0.05$); khi tăng ngưỡng lên 100, phân phối bị nén hơn.
Prewitt	Threshold $= 50, 100$	Cả hai cấu hình đều có ý nghĩa thống kê; cấu hình Threshold $= 100$ cho độ tách thấp hơn (ví dụ $F = 6.18$).

Bảng 15: Tổng hợp kết quả phát hiện cạnh và kiểm định ANOVA

Nhận xét:

1. Các biểu đồ boxplot cho thấy đặc trưng cạnh phân tách lớp tốt hơn đáng kể so với đặc trưng màu thô; các lớp giàu chi tiết biên như Chicken, Sheep, Squirrel có xu hướng mật độ cạnh cao hơn nhóm như Butterfly, Cat.

2. Kết quả ANOVA xác nhận khác biệt trung bình giữa các lớp ở cả 6 cấu hình (p-value đều rất nhỏ, nhỏ hơn nhiều so với $\alpha = 0.05$), do đó bác bỏ giả thuyết các lớp có cùng mật độ cạnh trung bình.

3. Cấu hình Canny $(50, 150)$ là lựa chọn tối ưu trong thí nghiệm này (F-statistic cao nhất), cho thấy cân bằng tốt giữa khử nhiễu và bảo toàn đường viền hữu ích cho phân loại.

Kết luận ngắn: Đặc trưng hình thái dựa trên đường viền có giá trị phân loại cao hơn đặc trưng pixel màu thô, là cơ sở để tiếp tục với các bộ mô tả hình dạng mạnh hơn như HOG/SIFT trong các bước tiếp theo.

4.3 Thực nghiệm dữ liệu bảng [4, 5, 6, 7, 8, 9]

4.3.1 B1. Phân tích tương quan đa biến (Pearson & Spearman)

Vẽ heatmap tương quan Pearson (đo mối quan hệ tuyến tính, nhạy với outlier) và Spearman (đo mối quan hệ đơn điệu, kháng nhiễu) giữa các thuộc tính số, nhằm xác định các cặp có khả năng đa cộng tuyến.

Phương pháp	**Đặc điểm chính**	**Khoảng giá trị**	**Phù hợp khi**
Pearson (r)	Đo tương quan tuyến tính, dùng giá trị thực.	$[-1, 1]$	Dữ liệu phân phối chuẩn, ít outlier.
Spearman (ρ)	Đo tương quan đơn điệu, dùng thứ hạng.	$[-1, 1]$	Dữ liệu bị lệch, nhiều outlier.

Bảng 16: B1 – So sánh hai phương pháp tương quan

Nhận xét: Kết quả heatmap cho thấy một số cặp thuộc tính có tương quan mạnh ($|r| \geq 0{,}7$ hoặc $|\rho| \geq 0{,}7$), là dấu hiệu của đa cộng tuyến. Đặc biệt, dữ liệu Building Permits có đặc thù là nhiều cột ngày tháng (Filed Date, Issued Date, Completed Date...) có tương quan cao. Khi phân tích nghiệp vụ, các mối tương quan này phản ánh đúng quy trình cấp phép xây dựng thực tế: dự án càng lớn thì chi phí càng cao, thời gian xử lý càng lâu.

4.3.2 B2. Phát hiện và xử lý ngoại lai

Cài đặt và so sánh 5 phương pháp phát hiện ngoại lai (9 cấu hình): IQR, Z-Score, Isolation Forest (3 mức contamination), LOF (3 mức $n_neighbors$), và DBSCAN. Đánh giá tỉ lệ phát hiện ngoại lai và độ chồng chéo (Jaccard Similarity) giữa các phương pháp.

Phương pháp	Số ngoại lai	Tỉ lệ (%)	Nhận xét
IQR (1,5×)	107.840	54,22	Over-detect nghiêm trọng do dữ liệu lệch phải.
Z-Score (3,0)	28.324	14,24	Vẫn cao do phân phối không chuẩn.
Isolation Forest ($c = 0{,}01$)	1.989	1,00	Bám sát tham số contamination.
Isolation Forest ($c = 0{,}05$)	9.945	5,00	Bám sát tham số contamination.
Isolation Forest ($c = 0{,}10$)	19.890	10,00	Bám sát tham số contamination.
LOF ($n = 10$)	636	0,32	Phát hiện cục bộ, kết quả khiêm tốn.
LOF ($n = 20$)	293	0,15	Tăng n giảm nhạy cảm.
LOF ($n = 50$)	137	0,07	Mất tính cục bộ, rất ít ngoại lai.
DBSCAN	467	0,23	Phát hiện dựa trên mật độ.

Bảng 17: B2 – Thống kê tỉ lệ ngoại lai theo 9 cấu hình

Nhận xét:

1. **IQR và Z-Score kém hiệu quả**: IQR phát hiện tới 54,22% ngoại lai – hơn nửa tập dữ liệu bị coi là bất thường. Điều này chứng tỏ dữ liệu chi phí xây dựng bị lệch phải cực mạnh, khiến hộp IQR rất hẹp và bất kỳ dự án quy mô vừa nào cũng bị văng ra ngoài ngưỡng $1{,}5 \times \text{IQR}$. Không nên áp dụng các phương pháp thống kê cổ điển cho dữ liệu tài chính/chi phí mà không qua bước chuẩn hóa logarit.

2. **LOF, DBSCAN hiệu quả hơn**: Các phương pháp dựa trên mật độ (LOF, DBSCAN) cho tỉ lệ ngoại lai rất thấp ($< 0{,}3\%$), phản ánh đúng bản chất dữ liệu: các dự án lớn không đứng đơn độc mà tạo thành cụm riêng trong không gian đa chiều.

3. **Jaccard Similarity** giữa các cặp phương pháp phần lớn ở mức thấp ($< 50\%$), cho thấy mỗi phương pháp nhìn nhận "ngoại lai" theo góc độ khác nhau.

4.3.3 B3. Chuẩn hóa dữ liệu có kiểm định

Áp dụng 4 phương pháp chuẩn hóa: Min-Max $[0, 1]$, Z-score, Robust Scaling, Quantile Transform. Sử dụng kiểm định Levene để đánh giá sự đồng nhất phương sai trước và sau chuẩn hóa. Trực quan hóa bằng Violin Plot.

Phương pháp	Nguyên lí	Đặc điểm
Min-Max $[0, 1]$	$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$	Đơn giản, nhạy outlier.
Z-score	$z = \frac{x - \mu}{\sigma}$	Đưa về $\mu \approx 0$, $\sigma \approx 1$; nhạy outlier.
Robust	Dùng Median và IQR	Kháng nhiễu tốt.
Quantile	Biến đổi phi tuyến	Đưa về phân phối Uniform hoặc Normal.

Bảng 18: B3 – So sánh 4 phương pháp chuẩn hóa

Nhận xét: Kiểm định Levene cho thấy phần lớn các cột bị bác bỏ H_0 (phương sai không đồng nhất) sau khi áp dụng Min-Max và Z-score, do dữ liệu có phân phối lệch mạnh và nhiều outlier. Riêng Robust Scaling cho kết quả tốt hơn ở một số cột nhờ sử dụng Median thay vì Mean, không bị ảnh hưởng bởi các giá trị cực trị. Quantile Transform ép dữ liệu về phân phối đồng đều hoặc chuẩn, phù hợp nhất khi cần đảm bảo đồng nhất phương sai.

4.3.4 B4. Mã hóa biến phân loại nâng cao

Áp dụng các phương pháp mã hóa: One-hot Encoding, Ordinal Encoding, Target Encoding, Binary Encoding, Frequency Encoding. Đo phương sai giải thích (Explained Variance) và phân tích đa cộng tuyến phát sinh.

Phương pháp	Ưu điểm	Hạn chế
One-hot	Không áp đặt thứ tự, dễ hiểu.	Tăng mạnh số chiều khi high cardinality.
Ordinal	Gọn nhẹ, giữ 1 cột.	Gán thứ tự giả cho biến nominal.
Target Encoding	Mã hóa theo trung bình target.	Dễ data leakage nếu không dùng K-Fold.
Binary Encoding	Nén tốt, ít cột hơn One-hot.	Mất khả năng giải thích.
Frequency Encoding	Đơn giản, nhanh.	Trùng giá trị nếu nhiều nhóm cùng tần suất.

Bảng 19: B4 – So sánh các phương pháp mã hóa biến phân loại

Nhận xét: One-hot Encoding dù trực quan nhưng gây bùng nổ chiều dữ liệu nghiêm trọng (với dữ liệu Building Permits có nhiều cột high cardinality như `Street Name`, `Description`). Target Encoding cho kết quả phương sai giải thích cao nhất nhưng cần triển khai cẩn thận với K-Fold để tránh data leakage. Binary Encoding là lựa chọn cân bằng giữa hiệu quả nén và hiệu năng mô hình.

4.3.5 B5. Lựa chọn và giảm chiều đặc trưng

Áp dụng pipeline 3 tầng: (1) Lọc thống kê (ANOVA, Chi-Square, Mutual Information), (2) Lọc mô hình (Random Forest, Gradient Boosting), (3) Giảm chiều (PCA). Báo cáo cross-validation F1-score và vẽ biểu đồ hiệu năng theo số đặc trưng.

Phương pháp	**Thuộc nhóm**	**Bản chất**	**Nhận xét**
ANOVA F-test	Lọc thống kê	Filter	Đánh giá mối quan hệ tuyến tính feature–target.
Chi-Square	Lọc thống kê	Filter	Dùng cho biến phân loại.
Mutual Information	Lọc thống kê	Filter	Bắt được quan hệ phi tuyến.
Random Forest	Lọc mô hình	Embedded	Feature importance dựa trên Gini.
Gradient Boosting	Lọc mô hình	Embedded	Feature importance dựa trên boosting.
PCA	Giảm chiều	Transform	Tạo thành phần mới, mất khả năng giải thích.

Bảng 20: B5 – Tổng hợp phương pháp lựa chọn đặc trưng

Nhận xét: Kết quả thực nghiệm cho thấy:

1. Các phương pháp thống kê (ANOVA, Chi-Square) có ưu điểm nhanh, dễ triển khai nhưng chỉ bắt được quan hệ tuyến tính, bỏ sót các mối quan hệ phức tạp hơn.

2. Mutual Information vượt trội hơn các phương pháp lọc thống kê nhờ khả năng phát hiện cả quan hệ phi tuyến.

3. Các phương pháp dựa trên mô hình (Random Forest, Gradient Boosting) cho kết quả feature importance đáng tin cậy hơn, phù hợp với đặc thù dữ liệu Building Permits có cấu trúc phức tạp.

4. PCA giảm chiều hiệu quả nhưng đánh đổi bằng việc mất khả năng giải thích ý nghĩa vật lý của từng đặc trưng, phù hợp khi ưu tiên hiệu năng mô hình hơn là khả năng giải trình.

4.3.6 B6. Phát hiện và xử lý mất cân bằng lớp

Mất cân bằng lớp (Class Imbalance) là hiện tượng phổ biến trong dữ liệu thực tế, khi nhóm đa số (Majority Class) áp đảo nhóm thiểu số (Minority Class), khiến mô hình phân loại bị thiên kiến (bias) nghiêng về lớp chiếm ưu thế. Nhóm áp dụng ba chiến lược tái cân bằng tiêu biểu: **Random Under-sampling (RUS)**, **SMOTE** và **ADASYN**, đánh giá trên bộ dữ liệu Building Permits với biến mục tiêu `Permit Type` (8 lớp).

Quy trình thực nghiệm:

1. **Kiểm tra mức độ mất cân bằng:** Phân phối lớp mục tiêu cho thấy lớp 8 chiếm 89.92%, trong khi lớp thiểu số nhất (lớp 5) chỉ chiếm 0.05% — tỷ lệ mất cân bằng cực độ lên tới $\approx 1966 : 1$.
2. **Chia tập Train/Test** (80/20, stratified) *trước khi* áp dụng bất kỳ kỹ thuật resampling nào nhằm ngăn chặn Data Leakage.
3. **Áp dụng Resampling** chỉ trên tập Train, giữ nguyên phân phối gốc của tập Test.
4. **Huấn luyện** mô hình Random Forest Classifier trên từng tập đã resampled.
5. **Đánh giá** trên tập Test gốc bằng bốn chỉ số: Precision (Macro), Recall (Macro), F1-Macro, và AUC-ROC (One-vs-Rest cho bài toán đa lớp).

Phương pháp	**Bản chất**	**Ưu điểm**	**Nhược điểm**	**Khi nào sử dụng**
Random Under-sampling (RUS)	Under-sampling	Nhanh, giảm kích thước dữ liệu	Mất mát thông tin, nguy cơ Underfitting	Dữ liệu khổng lồ, nhóm đa số dư thừa thông tin
SMOTE	Over-sampling (nội suy tuyến tính)	Giảm overfitting so với sao chép y hệt, mở rộng vùng đặc trưng thiểu số	Sinh dữ liệu "mù quáng", tăng nhiễu nếu lớp chồng lấn	Các lớp tách biệt tương đối rõ ràng
ADASYN	Over-sampling (thích ứng)	Tập trung vào vùng ranh giới khó phân loại	Nhạy cảm với ngoại lai, có thể khuếch đại nhiễu	Ranh giới phi tuyến phức tạp, dữ liệu đã dọn sạch outlier

Bảng 21: B6 – So sánh bản chất các kỹ thuật tái cân bằng lớp

Chiến lược Resampling	**Số mẫu Train**	**Precision**	**Recall**	**F1-Macro**	**AUC-ROC**
Original (Baseline)	159 120	0.8730	0.7994	**0.8259**	0.9833
Random Under-sampling	584	0.3638	0.8752	0.4380	0.9538
SMOTE	1 144 600	0.7980	0.8565	0.8149	0.9835
ADASYN	1 142 355	0.8017	0.8474	0.8152	**0.9843**

Bảng 22: B6 – Kết quả đánh giá hiệu năng các chiến lược xử lý mất cân bằng lớp (Building Permits, Target = `Permit Type`, Classifier = Random Forest)

Nhận xét: Kết quả thực nghiệm cho thấy:

1. **Baseline (Original)** đạt F1-Macro cao nhất (0.8259) nhờ Precision vượt trội (0.8730). Điều này cho thấy Random Forest vốn đã xử lý tương đối tốt nhờ cơ chế bootstrap sampling nội tại, đặc biệt khi lớp đa số áp đảo đến mức $\approx 90\%$.

2. **Random Under-sampling** gây sụt giảm hiệu năng nghiêm trọng: F1-Macro giảm 47% (từ 0.8259 xuống 0.4380). Nguyên nhân gốc rễ là việc chỉ giữ lại 584 mẫu (từ 159 120 mẫu ban đầu) làm mất gần như toàn bộ thông tin cấu trúc của nhóm đa số. Tuy Recall đạt cao nhất (0.8752) — tức mô hình "bắt" được nhiều mẫu thiểu số hơn — nhưng Precision cực thấp (0.3638) cho thấy tỷ lệ dương tính giả (False Positive) rất lớn. Chiến lược này *không phù hợp* với dữ liệu Building Permits có tỷ lệ mất cân bằng cực đoan.

3. **SMOTE** và **ADASYN** cho kết quả rất sát nhau (F1-Macro ≈ 0.815). Cả hai đều cải thiện Recall đáng kể so với Baseline (+5% đến +7%) nhờ cơ chế sinh mẫu nhân tạo giúp mô hình "nhìn thấy" nhóm thiểu số rõ hơn, nhưng đánh đổi bằng sự sụt giảm Precision ($\approx -8\%$) do một số mẫu sinh ra rơi vào vùng chồng lấn giữa các lớp.

4. **ADASYN** đạt AUC-ROC cao nhất (0.9843), nhỉnh hơn SMOTE (0.9835), xác nhận khả năng phân biệt tổng thể (discrimination ability) của mô hình được cải thiện nhờ cơ chế sinh mẫu thích ứng tập trung vào vùng ranh giới khó.

5. **Kết luận:** Với đặc thù dữ liệu Building Permits (8 lớp, mất cân bằng cực đoan), việc giữ nguyên phân phối gốc kết hợp mô hình Random Forest cho hiệu năng tốt nhất xét theo F1-Macro. Tuy nhiên, nếu ưu tiên khả năng phát hiện nhóm thiểu số (Recall), SMOTE hoặc ADASYN là lựa chọn hợp lý hơn.

4.4 Thực nghiệm dữ liệu chuỗi thời gian [10, 11, 12, 13]

Dưới đây là một số thực nghiệm trên bộ dữ liệu chuỗi thời gian COVID-19, ghi nhận số ca nhiễm, tử vong và phục hồi theo ngày tại nhiều quốc gia/vùng lãnh thổ từ tháng 1 đến tháng 10/2020.

- Bộ dữ liệu gồm các biến chính: `Confirmed`, `Deaths`, `Recovered` (tích lũy) và các biến dẫn xuất `New_Cases`, `New_Deaths`, `New_Recovered` (theo ngày).

- Các thực nghiệm bao gồm: phân tích thành phần chuỗi, thống kê trượt, cấu trúc tương quan ACF/PACF, kiểm định tính dừng, phân rã chuỗi, phát hiện dị thường, xây dựng ma trận đặc trưng dự báo, và kiểm định nhân quả Granger.

4.4.1 T1. Phân tích thành phần dữ liệu thời gian

Trực quan hóa các biến `Confirmed`, `Deaths`, `Recovered` bằng Time Plot để đánh giá xu hướng (Trend), tính mùa vụ (Seasonality) và nhiễu (Noise). Khảo sát trên khu vực Mỹ (US).

Biến	Xu hướng (Trend)	Nhận xét
Confirmed	Tăng liên tục, dạng hàm mũ	Phản ánh số ca tích lũy, tăng mạnh từ T6/2020.
Deaths	Tăng liên tục, dạng chữ S	Tăng dốc T4–T5, chậm lại nhờ cải thiện điều trị.
Recovered	Tăng liên tục, dốc đứng từ T6	Tỷ lệ thuận với số ca nhiễm.

Bảng 23: T1 – Đánh giá xu hướng các biến chính (US)

Nhận xét: Cả ba biến đều thể hiện xu hướng tăng liên tục (non-stationary) – đặc trưng của dữ liệu tích lũy. Biến `Confirmed` tại Mỹ dao động biên độ lớn theo hình răng cưa, minh chứng rõ cho tính chu kỳ tuần (Weekly Seasonality) do độ trễ báo cáo hành chính (cuối tuần giảm, đầu tuần tăng vọt). Kết quả này hỗ trợ quyết định sử dụng sai phân (differencing) và chu kỳ $period = 7$ ở các thí nghiệm sau.

4.4.2 T2. Kiểm định tính dừng bằng Rolling Statistics

Tính Rolling Mean và Rolling STD trên các cửa sổ $W \in \{7, 30, 90\}$ ngày để đánh giá trực quan tính dừng của chuỗi. Nếu Rolling Mean không phẳng hoặc Rolling STD dao động mạnh thì chuỗi không dừng.

Chỉ số	Công thức	Ý nghĩa
Rolling Mean	$\overline{Y}_t = \frac{1}{W}\sum_{i=0}^{W-1} Y_{t-i}$	Kỳ vọng cục bộ; phẳng ⇒ dừng.
Rolling STD	$\sigma_t = \sqrt{\frac{1}{W}\sum_{i=0}^{W-1}(Y_{t-i} - \overline{Y}_t)^2}$	Phương sai cục bộ; ổn định ⇒ dừng.

Bảng 24: T2 – Công thức Rolling Statistics

Nhận xét: Cả 3 đường Rolling Mean ($W = 7, 30, 90$) của biến `Confirmed` (US) đều tăng liên tục, cho thấy kỳ vọng thay đổi theo thời gian – chuỗi **không dừng**. Rolling STD cũng dao động mạnh, phương sai không ổn định. Cửa sổ $W = 90$ làm mượt quá mức, mất khả năng phát hiện biến động ngắn hạn. Kết quả trực quan này sẽ được xác nhận bằng kiểm định thống kê ở thí nghiệm T4.

4.4.3 T3. Phân tích cấu trúc tương quan (ACF & PACF)

Vẽ biểu đồ ACF (Autocorrelation Function) và PACF (Partial Autocorrelation Function) với $n_lags = 40$ để xác định cấu trúc phụ thuộc thời gian và hỗ trợ lựa chọn bậc cho mô hình dự báo.

Hàm	Đặc điểm	Ứng dụng
ACF	Đo tương quan giữa Y_t và Y_{t-k} (bao gồm cả ảnh hưởng gián tiếp).	Xác định bậc q cho mô hình MA.
PACF	Đo tương quan trực tiếp giữa Y_t và Y_{t-k} (loại bỏ ảnh hưởng trung gian).	Xác định bậc p cho mô hình AR.

Bảng 25: T3 – So sánh ACF và PACF

Nhận xét:

1. Biểu đồ ACF của biến `Confirmed` (US) cho thấy hệ số tương quan giảm rất chậm (suy giảm tuyến tính), đặc trưng của chuỗi không dừng có xu hướng mạnh.
2. PACF cho thấy Lag 1 có hệ số xấp xỉ 1,0, sau đó giảm đột ngột – xác nhận cấu trúc AR(1) chiếm ưu thế. Số ca hôm nay gần như được quyết định hoàn toàn bởi hôm qua.
3. Kết quả PACF hỗ trợ lựa chọn bậc trễ p khi xây dựng ma trận đặc trưng (lag features) ở thí nghiệm T7.

4.4.4 T4. Kiểm định tính dừng và biến đổi khử tính không dừng

Áp dụng 3 kiểm định: ADF (Augmented Dickey-Fuller), KPSS (Kwiatkowski–Phillips–Schmidt–Shin) và PP (Phillips-Perron) trên chuỗi gốc `New_Cases`. Sau đó biến đổi bằng 4 phương pháp: Log, Box-Cox, Sai phân bậc 1 ($d = 1$), Sai phân bậc 2 ($d = 2$) và kiểm định lại.

Kiểm định	Giả thuyết H_0	p-value	Kết luận (chuỗi gốc)
ADF	Chuỗi có nghiệm đơn vị (không dừng).	$\approx 0{,}98$	Không bác bỏ H_0: **không dừng**.
KPSS	Chuỗi là dừng.	$\approx 0{,}01$	Bác bỏ H_0: **không dừng**.
PP	Chuỗi có nghiệm đơn vị (không dừng).	$\approx 0{,}71$	Không bác bỏ H_0: **không dừng**.

Bảng 26: T4 – Kết quả kiểm định tính dừng trên chuỗi gốc `New_Cases` (US)

Nhận xét:

1. Cả 3 kiểm định đồng thuận: chuỗi `New_Cases` gốc là **không dừng**, phù hợp với quan sát trực quan từ Rolling Statistics (T2).
2. Sau khi áp dụng sai phân bậc 1 ($d = 1$), kiểm định ADF cho p-value ≈ 0 – bác bỏ H_0, xác nhận chuỗi đã trở nên dừng. Đây là phương pháp biến đổi tối ưu cho bộ dữ liệu COVID.

3. Log và Box-Cox không đủ mạnh để khử xu hướng tuyến tính, chỉ hiệu quả với dữ liệu lệch phải. Sai phân bậc 2 ($d = 2$) gây mất quá nhiều thông tin, không cần thiết.

4.4.5 T5. Phân rã chuỗi thời gian (Additive, Multiplicative, STL)

Phân rã chuỗi thành 3 thành phần: Trend, Seasonal, Residual bằng 3 phương pháp: Additive ($Y_t = T_t + S_t + R_t$), Multiplicative ($Y_t = T_t \times S_t \times R_t$) và STL (Seasonal-Trend decomposition using LOESS). Đánh giá bằng tỷ lệ phương sai phần dư (Noise Ratio = $\mathrm{Var}(R)/\mathrm{Var}(Y)$).

Phương pháp	**Period**	**Noise Ratio**	**Nhận xét**
Additive	7	1,96%	Hiệu quả tốt, phù hợp khi biên độ mùa vụ không đổi.
Multiplicative	7	1,95%	Nhỉnh hơn Additive rất nhỏ (0,01%).
STL (robust)	7	**1,47%**	Tốt nhất nhờ LOESS linh hoạt và kháng outlier.
STL (robust)	14	2,13%	Chu kỳ 2 tuần kém hơn 7 ngày.
STL (robust)	30	10,87%	Quá dài, mất khả năng bắt mùa vụ tuần.

Bảng 27: T5 – So sánh phương pháp phân rã (biến Daily Confirmed – US)

Nhận xét:

1. Chu kỳ $period = 7$ luôn cho Noise Ratio thấp nhất, phản ánh chính xác "hiệu ứng hành chính" trong y tế: số ca giảm vào cuối tuần do giảm xét nghiệm và báo cáo, tăng vọt đầu tuần do công bố bù.

2. STL vượt trội nhờ sử dụng LOESS (Local Regression) cho phép trend thay đổi linh hoạt theo thời gian, và chế độ `robust=True` giảm ảnh hưởng của outlier.

3. Không thể áp dụng rập khuôn một phương pháp cho mọi khu vực: tại Hàn Quốc (dịch kiểm soát chặt), kết quả phân rã có hình thái hoàn toàn khác so với Mỹ.

4.4.6 T6. Phát hiện dị thường trong chuỗi thời gian

Cài đặt và so sánh 3 phương pháp phát hiện dị thường: Z-Score (trên chuỗi đã khử mùa vụ), Isolation Forest (cửa sổ trượt $W = 7$), và STL Residual Thresholding (ngưỡng IQR trên phần dư). Khảo sát trên 4 quốc gia: Mỹ, Ý, Brazil, Việt Nam.

Phương pháp	Nguyên lý	Đặc điểm
Z-Score (Deseasonalized)	$\|z\| > 3$ sau khử mùa vụ bằng STL.	Chỉ bắt outlier cực trị, bỏ sót nhiều.
Isolation Forest ($W = 7$)	Cô lập điểm bất thường bằng Random Forest trên lag features.	Phát hiện ở mức trung bình, bám sát `contamination`.
STL Residual Thresholding	IQR $\times$1,5 trên phần dư STL.	Phát hiện nhiều nhất, nhạy cảm với dao động ngắn hạn.

Bảng 28: T6 – So sánh 3 phương pháp phát hiện dị thường

Nhận xét:

1. **STL Residual Thresholding** phát hiện được nhiều dị thường nhất trên tổng thể 4 quốc gia nhờ ngưỡng IQR nhạy cảm với dao động ngắn hạn. **Z-Score** gần như không phát hiện được điểm nào ngoài các đỉnh cực trị.

2. Mức độ trùng nhau giữa 3 phương pháp cực kỳ thấp (Intersection cả 3 ≈ 0 ở hầu hết quốc gia), chứng tỏ mỗi phương pháp nhìn nhận "dị thường" theo góc độ toán học khác nhau.

3. Cửa sổ $W = 7$ là tối ưu cho Isolation Forest: $W = 3$ quá nhạy cảm với dao động cuối tuần, $W = 14$ lại bỏ sót biến động ngắn hạn.

4. Biến số nhiễu nhất là `Deaths` (192 điểm) và `New_Cases` (191 điểm) – hai chỉ số chịu áp lực báo cáo công khai hằng ngày, dễ bị tác động bởi lỗi hành chính.

5. Đối chiếu với sự kiện thực tế cho thấy các điểm dị thường thuộc 2 nhóm: (A) lỗi dồn báo cáo y tế (rơi vào đầu tuần/sau ngày lễ), và (B) đỉnh điểm bùng phát dịch thực sự.

4.4.7 T7. Xây dựng ma trận đặc trưng và dự báo $t + 1$

Xây dựng pipeline 4 bước tạo ma trận đặc trưng từ chuỗi thời gian, sau đó huấn luyện Random Forest Regressor (RFR) để dự báo `New_Cases` bước kế tiếp ($t + 1$). Chia train/test theo thời gian (80/20), đánh giá bằng MAE và RMSE.

Bước	Mô tả	Chi tiết cấu hình
1	Lag features từ PACF	p tự chọn từ PACF; chặn trên $p_{max} = 14$.
2	Rolling statistics đa cửa sổ	$W \in \{7, 30, 90\}$; shift(1) tránh data leakage.
3	Time features (lịch thời gian)	`dayofweek`, `month`, `is_weekend`, sin/cos encoding.
4	Decomposition features (STL)	Trend, Seasonal, Residual (lag 1); $period = 7$, robust.

Bảng 29: T7 – Pipeline xây dựng ma trận đặc trưng

Nhận xét:

1. Mô hình RFR ($n_estimators = 500$, $max_depth =$ None) trên tập test cho hệ số tương quan giữa y_{true} và y_{pred} xấp xỉ 0,713 – mô hình bám được nhịp tăng giảm ngắn hạn.

2. Tuy nhiên, mô hình có hiện tượng *làm mượt*: các đỉnh nhọn bị dự báo thấp hơn thực tế, các đáy sâu bị dự báo cao hơn – hạn chế cố hữu của RFR khi dự báo giá trị ngoài miền huấn luyện.

3. Kỹ thuật `shift(1)` được áp dụng nhất quán cho tất cả rolling features và decomposition features để đảm bảo tại thời điểm t chỉ sử dụng thông tin quá khứ, tránh rò rỉ dữ liệu.

4. Đề xuất cải thiện: bổ sung biến ngoại sinh (policy index, mobility, vaccination rate), nâng cấp mô hình (Gradient Boosting, LSTM), và mở rộng dữ liệu theo thời gian.

4.4.8 Nâng cao - T8. Kiểm định nhân quả Granger (Bonus)

Kiểm định Granger Causality giữa các cặp biến `Confirmed`, `Deaths`, `Recovered` (sau sai phân bậc 1) tại khu vực US. Giả thuyết H_0: thông tin quá khứ của biến X *không* giúp dự báo biến Y tốt hơn. Nếu $p < 0{,}05$, bác bỏ H_0.

Khái niệm	Định nghĩa	Lưu ý
Granger Cause	X Granger-gây ra Y nếu quá khứ X cải thiện dự báo Y có ý nghĩa thống kê.	Không khẳng định nhân quả cơ chế, chỉ đánh giá chiều ảnh hưởng theo thời gian.
Điều kiện	Chuỗi phải dừng (stationary) trước khi kiểm định.	Cần sai phân trước nếu chuỗi gốc không dừng.

Bảng 30: T8 – Khái niệm Granger Causality

Nhận xét:

1. Kết quả kiểm định trên 269 quan sát (US) cho thấy tồn tại mối quan hệ Granger có ý nghĩa thống kê giữa một số cặp biến: quá khứ của `Confirmed` giúp dự báo `Deaths` (phản ánh độ trễ sinh học từ nhiễm bệnh đến tử vong).

2. Điều kiện tiên quyết: tất cả các chuỗi phải được sai phân bậc 1 trước khi kiểm định để đảm bảo tính dừng, tránh hồi quy giả (spurious regression).

3. Ứng dụng: kết quả Granger hỗ trợ quyết định bổ sung biến ngoại sinh vào mô hình dự báo – nếu biến X Granger-gây ra Y, thì thêm lag features của X vào ma trận đặc trưng có thể cải thiện dự báo Y.

5 Môi trường và cài đặt

5.0.1 Phần cứng

Các thực nghiệm được thực hiện trên máy tính cá nhân với cấu hình tối thiểu như sau:

Thành phần	**Yêu cầu tối thiểu**
CPU	Intel Core i5 thế hệ 8 trở lên (hoặc tương đương)
RAM	8 GB (khuyến nghị 16 GB cho xử lý ảnh)
Ổ cứng	SSD, trống tối thiểu 10 GB
GPU	Không bắt buộc (toàn bộ tính toán chạy trên CPU)

Bảng 31: Cấu hình phần cứng tối thiểu

5.0.2 Phần mềm

Phần mềm	**Phiên bản / Ghi chú**
Hệ điều hành	Windows 10/11, macOS, hoặc Linux
Python	3.10+ (khuyến nghị 3.11)
Git	Phiên bản mới nhất
IDE	VS Code + Python Extension + Jupyter Extension
Quản lý gói	pip + virtual environment (`venv`)

Bảng 32: Phần mềm sử dụng

5.0.3 Thư viện chính

Toàn bộ thư viện được khai báo trong file `requirements.txt` và cài đặt qua `pip`. Bảng 33 liệt kê các nhóm thư viện chính:

Nhóm	Thư viện	Mục đích
Khoa học dữ liệu	numpy, pandas, scikit-learn, scipy, statsmodels, arch	Tính toán số, xử lý bảng, ML, kiểm định thống kê.
Trực quan hóa	matplotlib, seaborn, missingno	Vẽ biểu đồ, heatmap, ma trận thiếu dữ liệu.
Xử lý ảnh	opencv-python, Pillow, imagehash	Đọc/ghi ảnh, biến đổi, phát hiện trùng lặp.
Giảm chiều	umap-learn	Trực quan hóa không gian đặc trưng.
Tiện ích	tqdm, tabulate	Thanh tiến trình, định dạng bảng.

Bảng 33: Các nhóm thư viện chính

5.1 Quản lý mã nguồn

5.1.1 Repository

Mã nguồn được quản lý trên GitHub tại:

https://github.com/Taylor3691/data-mining-preprocessing-project

Quy trình làm việc tuân theo mô hình **Feature Branch Workflow**: mỗi thành viên phát triển trên nhánh riêng (ví dụ `feature/normalization`, `feature/outlier-detection`), sau đó tạo Pull Request để merge vào nhánh chính.

5.1.2 Kiến trúc mã nguồn

Dự án phân tách rõ ràng giữa **mã xử lý logic** (file `.py` trong `src/`) và **báo cáo thực nghiệm** (file `.ipynb` trong `notebooks/`). Cụ thể:

- `src/core/`: Các lớp trừu tượng (abstract class) định nghĩa khuôn mẫu cho Dataset, Service, Preprocessing, Visualization.
- `src/image/`, `src/table/`, `src/time_series/`: Module xử lý logic cho từng kiểu dữ liệu (dataset, analysis, preprocessing).
- `src/statistic/`: Các hàm kiểm định thống kê (Shapiro-Wilk, Levene, ADF, KPSS, ...).
- `src/visualization/`: Các hàm trực quan hóa, chia theo nhóm biểu đồ (distribution, comparison, relationship, evaluation).
- `src/config/`, `src/utils/`: Cấu hình đường dẫn và tiện ích đọc/ghi file.
- `notebooks/`: File Jupyter Notebook chỉ dùng để gọi hàm và báo cáo kết quả, **không chứa logic xử lý**.

5.2 Bộ dữ liệu

Dự án sử dụng 3 bộ dữ liệu từ Kaggle:

Nhóm	Tên dataset	Quy mô
Ảnh	Animals-10 [15]	26.179 ảnh, 10 lớp
Bảng	Building Permits [16]	198.900 dòng, 43 cột
Chuỗi thời gian	COVID-19 Time Series [17]	T1–T10/2020, đa quốc gia

Bảng 34: Danh sách bộ dữ liệu sử dụng

5.3 Hướng dẫn cài đặt và chạy thực nghiệm

5.3.1 Bước 1: Clone mã nguồn và tạo môi trường ảo

```
git clone https://github.com/Taylor3691/data-mining-preprocessing-project.git
cd data-mining-preprocessing-project
python -m venv .venv
# Windows: .\.venv\Scripts\Activate.ps1
# Linux/macOS: source .venv/bin/activate
```

5.3.2 Bước 2: Cài đặt thư viện

```
pip install --upgrade pip
pip install -r requirements.txt
pip install -e .
```

5.3.3 Bước 3: Tải và đặt dataset

Tải 3 bộ dữ liệu từ Kaggle (xem Bảng 34), giải nén và đặt vào thư mục `data/` theo cấu trúc:

```
data/
  image/ # 10 thu muc: dog, cat, horse, ...
  table/ # Building_Permits.csv
  time_series/ # time-series-19-covid-combined.csv
```

Lưu ý: Dataset ảnh Animals-10 có thể xuất hiện tên thư mục bằng tiếng Ý (ví dụ `cane`, `gatto`). Cần đổi tên về tiếng Anh (`dog`, `cat`, ...) trước khi chạy.

5.3.4 Bước 4: Chạy thực nghiệm

Mở VS Code, chọn Python interpreter là `.venv`, mở file notebook trong thư mục `notebooks/` và chạy các cell từ trên xuống dưới.

Tài liệu

[1] R. C. Gonzalez and R. E. Woods, *Digital Image Processing.* Pearson, 4 ed., 2018.

[2] ITU-R, "Recommendation bt.601-7: Studio encoding parameters of digital television for standard 4:3 and wide-screen 16:9 aspect ratios," recommendation, International Telecommunication Union, 2011.

[3] G. Wyszecki and W. S. Stiles, *Color Science: Concepts and Methods, Quantitative Data and Formulae.* Wiley-Interscience, 2 ed., 2000.

[4] R. J. A. Little, "A test of missing completely at random for multivariate data with missing values," *Journal of the American Statistical Association*, vol. 83, no. 404, pp. 1198–1202, 1988.

[5] R. B. D'Agostino, "An omnibus test of normality for moderate and large size samples," *Biometrika*, vol. 58, no. 2, pp. 341–348, 1971.

[6] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," in *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, pp. 413–422, IEEE, 2008.

[7] M. M. Breunig, H.-P. Kriegel, R. T. Ng, and J. Sander, "LOF: Identifying density-based local outliers," in *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, pp. 93–104, ACM, 2000.

[8] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, pp. 226–231, 1996.

[9] F. Pedregosa, G. Varoquaux, A. Gramfort, *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[10] D. A. Dickey and W. A. Fuller, "Distribution of the estimators for autoregressive time series with a unit root," *Journal of the American Statistical Association*, vol. 74, no. 366, pp. 427–431, 1979.

[11] R. B. Cleveland, W. S. Cleveland, J. E. McRae, and I. Terpenning, "STL: A seasonal-trend decomposition procedure based on loess," *Journal of Official Statistics*, vol. 6, no. 1, pp. 3–33, 1990.

[12] C. W. J. Granger, "Investigating causal relations by econometric models and cross-spectral methods," *Econometrica*, vol. 37, no. 3, pp. 424–438, 1969.

[13] G. E. P. Box and D. R. Cox, "An analysis of transformations," *Journal of the Royal Statistical Society: Series B*, vol. 26, no. 2, pp. 211–252, 1964.

[14] "Data mining preprocessing project - assignment sheet." https://docs.google.com/spreadsheets/d/1rtoR6K0IoPLpgj9U4qKEQ-JOqeFfI-DcvqiA9hehfnI/edit?usp=sharing. Accessed: 2026-04-22.

[15] A. Corrado, "Animals10: Animal pictures of 10 different categories taken from google images." https://www.kaggle.com/datasets/alessiocorrado99/animals10, dec 2019. Truy cập ngày 20/04/2026.

[16] A. Shastry, "San francisco building permits: 5 years and 200k building permits." https://www.kaggle.com/datasets/aparnashastry/building-permit-applications-data, mar 2018. Nguồn gốc: SF Open Data Portal. Truy cập ngày 20/04/2026.

[17] N. Chauhan, "Covid-19 time series data: The covid-19 cases all around the world." https://www.kaggle.com/datasets/niketchauhan/covid-19-time-series-data, nov 2020. Nguồn gốc: Johns Hopkins University CSSE. Truy cập ngày 20/04/2026.